

Laboratorium: Strojenie hiperparametrów

May 23, 2023

1 Zakres ćwiczeń

- Zbadanie wpływu poszczególnych hiperparametrów na proces uczenia i jakość modelu.
- Zaobserwowanie niekorzystnych efektów w procesie uczenia (np. niestabilność gradientów).
- Zbadanie różnic w działaniu algorytmów optymalizacji innych niż SGD.
- Automatyzacja poszukiwania optymalnych hiperparametrów przy pomocy:
 - wrappera [scikeras](#) i narzędzi optymalizacyjnych [scikit-learn](#),
 - pakietu [KerasTuner](#).

2 Zadania

2.1 Pobieranie danych

Pobierz zestaw danych [California Housing](#) i dokonaj jego podziału oraz normalizacji:

```
from sklearn.datasets import fetch_california_housing
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler

housing = fetch_california_housing()

X_train_full, X_test, y_train_full, y_test = train_test_split(housing.data,
    ↪housing.target, random_state=42)
X_train, X_valid, y_train, y_valid = train_test_split(X_train_full,
    ↪y_train_full, random_state=42)

scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_valid = scaler.transform(X_valid)
X_test = scaler.transform(X_test)
```

2.2 Przeszukiwanie przestrzeni hiperparametrów przy pomocy scikit-learn

Celem ćwiczenia jest przejrzenie przestrzeni parametrów w następujących zakresach:

1. krok uczenia: $[3 \cdot 10^{-4}, 3 \cdot 10^{-2}]$,
2. liczba warstw ukrytych: od 0 do 3,
3. liczba neuronów na warstwę: od 1 do 100,
4. algorytm optymalizacji: adam, sgd lub nesterov.

W tym ćwiczeniu wykorzystamy narzędzie `RandomizedSearchCV` pakietu `scikit-learn`.

Aby móc go użyć, należy nasz model obudować wrapperem `scikeras`.

Przygotuj słownik zawierający przeszukiwane wartości parametrów:

```
param_distributions = {
    "model__n_hidden": ...,
    "model__n_neurons": ...,
    "model__learning_rate": ...,
    "model__optimizer": ...
}
```

Listę wartości reprezentujących rozkład dla kroku uczenia możesz uzyskać np. przy pomocy `tej funkcji` pakietu `SciPy`:

```
from scipy.stats import reciprocal
reciprocal(3e-4, 3e-2).rvs(1000).tolist()
```

Przygotuj funkcję:

```
def build_model(n_hidden, n_neurons, optimizer, learning_rate):
    model = tf.keras.models.Sequential()
    # ...
    # model.compile(...)
    return model
```

budującą model według parametrów podanych jako argumenty:

- `n_hidden` – liczba warstw ukrytych,
- `n_neurons` – liczba neuronów na każdej z warstw ukrytych,
- `optimizer` – gradientowy algorytm optymalizacji, funkcja powinna rozumieć wartości: `sgd`, `nesterov`, `momentum` oraz `adam`,
- `learning_rate` – krok uczenia.

Przygotuj callback *early stopping* i obuduj przygotowaną wcześniej funkcję `build_model` obiektem `KerasRegressor`:

```
import scikeras
from scikeras.wrappers import KerasRegressor

es = tf.keras.callbacks.EarlyStopping(patience=10, min_delta=1.0, verbose=1)

keras_reg = KerasRegressor(build_model, callbacks=[es])
```

Przygotuj obiekt `RandomizedSearchCV`, tak aby wykonał 10 iteracji przy 3-krotnej walidacji krzyżowej, a następnie przeprowadź uczenie:

```
from sklearn.model_selection import RandomizedSearchCV

rnd_search_cv = RandomizedSearchCV(keras_reg,
                                    param_distributions,
                                    n_iter=10,
```

```

cv=3,
verbose=2)

rnd_search_cv.fit(X_train, y_train, epochs=100, validation_data=(X_valid,
↪y_valid), verbose=0)

```

Zapisz najlepsze znalezione parametry w postaci słownika do pliku `rnd_search_params.pkl` w postaci słownika o następującej strukturze:

```

{'model__optimizer': 'adam',
 'model__n_neurons': 42,
 'model__n_hidden': 3,
 'model__learning_rate': 0.004003820130936959}

```

4 pkt.

Zapisz obiekt `RandomizedSearchCV` do pliku `rnd_search_scikeras.pkl`.

6 pkt.

2.3 Przeszukiwanie przestrzeni hiperparametrów przy pomocy Keras Tuner

Przeprowadź podobny eksperyment przy pomocy `KerasTuner`. Przyjmij identyczne jak w poprzednim ćwiczeniu zakresy hiperparametrów.

Przygotuj funkcję `build_model_kt`, przyjmującą obiekt `HyperParameters` jako wejście. Powinna ona w pierwszej części definiować hiperparametry, a w drugiej – przeprowadzić budowę modelu:

```
import keras_tuner as kt
```

```

def build_model_kt(hp):
    n_hidden = hp.Int("n_hidden", min_value=0, max_value=3, default=2)
    # (...)

    model = tf.keras.models.Sequential()
    # (...)

    # model.compile(...)
    return model

```

Przygotuj wybrany *tuner* spośród dostępnych w `Keras Tuner`, np.:

```

random_search_tuner = kt.RandomSearch(
    build_model, objective="val_mse", max_trials=10, overwrite=True,
    directory="my_california_housing", project_name="my_rnd_search", seed=42)

```

Przygotuj również callback `TensorBoard` do zbierania danych w podkatalogu `tensorboard` w katalogu projektu:

```

root_logdir = os.path.join(random_search_tuner.project_dir, 'tensorboard')
tb = tf.keras.callbacks.TensorBoard(root_logdir)

```

Uruchom przeszukiwanie dla maksymalnie 100 epok na próbę. Pamiętaj o podaniu danych weryfikacyjnych (`X_valid`, `y_valid`) oraz utworzonego przed chwilą callbacku TensorBoard oraz stworzonego wcześniej callbacku *early stopping*.

Uruchom TensorBoard i przeanalizuj proces strojenia hiperparametrów w zakładce *HPARAMS*:

```
%load_ext tensorboard
%tensorboard --logdir {root_logdir}
```

Zapisz do pliku `kt_search_params.pkl` parametry najlepszego znalezionej modelu w postaci słownika, np.:

```
{'n_hidden': 3,
 'n_neurons': 45,
 'learning_rate': 0.0008960175671873151,
 'optimizer': 'adam'}
```

4 pkt.

Zapisz najlepszy uzyskany model do pliku `kt_best_model.h5`.

6 pkt.

3 Prześlij rozwiązanie

Skrypt wykonujący powyższe zadania umieść w swoim repozytorium, w pliku `lab11/lab11.py`.